

# Ekonometria Finansowa

## Jednowymiarowe modele szeregów czasowych

mgr Paweł Jamer<sup>1</sup>

16 listopada 2015

---

<sup>1</sup>pawel.jamer@gmail.com

# Biały szum

## Biały szum

Białym szumem nazwiemy szereg czasowy  $\epsilon_t$  niezależnych zmiennych losowych o tym samym rozkładzie taki, że

$$\begin{aligned}\mathbb{E}(\epsilon_t) &= 0, \\ \text{Var}(\epsilon_t) &= \sigma^2.\end{aligned}$$

Biały szum oznaczać będziemy symbolem  $\text{WN}(0, \sigma^2)$ .

**Uwaga** Bardziej złożone modele szeregów czasowych wykorzystują biały szum do opisu niepewności pomiaru opisywanych przez nie wielkości.

# Błądzenie losowe

## Błądzenie losowe (bez dryftu)

Szereg czasowy  $p_t$  nazwiemy błądzeniem losowym bez dryftu, jeżeli spełnia on równanie

$$p_t = p_{t-1} + \epsilon_t,$$

gdzie

- $\epsilon_t$  — biały szum.

**Uwaga.** Uzupełniając powyższy wzór o niezerową stałą  $\alpha$

$$p_t = \alpha + p_{t-1} + \epsilon_t$$

uzyskujemy proces błądzenia losowego z dryftem.

# Ceny instrumentów finansowych

## Hipoteza

Cena instrumentu finansowego  $p_t$  jest błądzeniem losowym.

Rozważmy model

$$p_t = \alpha + \rho p_{t-1} + \epsilon_t.$$

Prawdziwość powyższej hipotezy jest równoznaczna z tym, że:

- $\hat{\rho}$  statystycznie nie różni się od jedności,
- $\epsilon_t$  jest białym szumem.

Ponadto, jeżeli na zadanym poziomie istotności zachodzi:

- $\hat{\alpha} = 0$ , to  $p_t$  jest błądzeniem losowym bez dryfu,
- $\hat{\alpha} \neq 0$ , to  $p_t$  jest błądzeniem losowym z dryfem.

**Uwaga.** Z powodu możliwej niestacjonarności  $p_t$  estymacja powyższego równania jest problematyczna.

# Właściwości błędzenia losowego

## Błądzenie losowe bez dryftu

$$p_t = p_{t-1} + \epsilon_t,$$

$$p_t = p_0 + \sum_{h=0}^t \epsilon_{t-h},$$

$$\mathbb{E}(p_t) = p_0,$$

$$\text{Var}(p_t) = t\sigma_{\epsilon_t}^2.$$

## Błądzenie losowe z dryftem

$$p_t = \alpha + p_{t-1} + \epsilon_t,$$

$$p_t = p_0 + t\alpha + \sum_{h=0}^t \epsilon_{t-h},$$

$$\mathbb{E}(p_t) = p_0 + t\alpha,$$

$$\text{Var}(p_t) = t\sigma_{\epsilon_t}^2.$$

# Stopy zwrotu instrumentów finansowych

Rozważmy model błędzenia losowego bez dryftu dla logarytmu cen pewnego instrumentu finansowego

$$\log(p_t) = \log(p_{t-1}) + \epsilon_t.$$

Model ten przekształcić możemy do postaci

$$r_t = \log\left(\frac{p_t}{p_{t-1}}\right) = \epsilon_t.$$

**Uwaga.** Badanie czy logarytm cen  $p_t$  instrumentu finansowego jest błędzeniem losowym sprowadza się do ustalenia, czy logarytmiczne stopy zwrotu  $r_t$  tego instrumentu są białym szumem.

# Krytyka

Optymalna prognoza ceny instrumentu finansowego na okres przyszły, to przyjęcie ceny tego instrumentu z okresu bieżącego.

Nie uwzględnia się rentowności zależnej od ryzyka.

# Proces AR

Zdefiniujmy operator

$$\varphi(B) = I - \varphi_1 B - \dots - \varphi_p B^p,$$

gdzie  $p \in \mathbb{Z}_+$ .

## Proces AR

Słabo stacjonarny szereg czasowy  $X_t$  nazwiemy procesem AR (autoregresyjnym) rzędu  $p$ , jeżeli spełnia on równanie

$$\varphi(B) X_t = \epsilon_t,$$

gdzie  $\epsilon_t \sim \text{WN}(0, \sigma^2)$ .

**Oznaczenie.** Proces AR rzędu  $p$  oznacza się symbolem  $\text{AR}(p)$ .



# Proces MA

Zdefiniujmy operator

$$\theta(B) = I + \theta_1 B + \dots + \theta_q B^q,$$

gdzie  $q \in \mathbb{Z}_+$ .

## Proces MA

Słabo stacjonarny szereg czasowy  $X_t$  nazwiemy procesem MA (średniej ruchomej) rzędu  $q$ , jeżeli spełnia on równanie

$$X_t = \theta(B) \epsilon_t,$$

gdzie  $\epsilon_t \sim \text{WN}(0, \sigma^2)$ .

**Oznaczenie.** Proces MA rzędu  $q$  oznacza się symbolem  $\text{MA}(q)$ .

# Proces ARMA

## Definicja

### Proces ARMA

Słabo stacjonarny szereg czasowy  $X_t$  nazwiemy procesem ARMA  $(p, q)$ , jeżeli spełnia on równanie

$$\varphi(B) X_t = \theta(B) \epsilon_t,$$

gdzie  $\epsilon_t \sim \text{WN}(0, \sigma^2)$ .

# Proces ARMA

## Estymowanie funkcji autokorelacji (ACF)

### Estymator funkcji autokorelacji

Jako estymator funkcji autokorelacji procesu  $X_t$  możemy przyjąć

$$\hat{\rho}_h = \frac{\sum_{t=h}^T (X_t - \bar{X}) (X_{t-h} - \bar{X})}{\sum_{t=1}^T (X_t - \bar{X})^2}$$

# Proces ARMA

## Estymowanie funkcji autokorelacji częściowej (PACF)

### Estymator funkcji autokorelacji częściowej

Jako estymator funkcji autokorelacji częściowej procesu  $X_t$  możemy przyjąć

$$\alpha_0 = 1,$$

$$\alpha_1 = \phi_{1,1} = \hat{\rho}_1,$$

$$\alpha_h = \phi_{h,h} = \frac{\hat{\rho}_h - \sum_{j=1}^{h-1} \phi_{h-1,j} \hat{\rho}_{h-j}}{1 - \sum_{j=1}^{h-1} \phi_{h-1,j} \hat{\rho}_j}, h = 2, 3, \dots,$$

gdzie  $\phi_{i,j}$  to rozwiązania układu Yule'a-Walkera.

**Intuicja.** Współczynnik autokorelacji częściowej mierzy korelację między zmiennymi  $X_t$  oraz  $X_{t-h}$  po eliminacji wpływu zmiennych pośrednich.

# Proces ARMA

## Identyfikacja na podstawie ACF oraz PACF

- Jeżeli proces jest typu  $AR(p)$ , to funkcja autokorelacji powoli maleje, natomiast funkcja autokorelacji częściowej staje się statystycznie równa zero od wartości  $p + 1$ .
- Jeżeli proces jest typu  $MA(q)$ , to funkcja autokorelacji staje się statystycznie równa zero od wartości  $q + 1$ , natomiast funkcja autokorelacji częściowej powoli maleje.
- Jeżeli proces jest typu  $ARMA(p, q)$ , to funkcja autokorelacji oraz funkcja autokorelacji częściowej łagodnie zanikają.

# Proces ARMA

## Identyfikacja na podstawie kryteriów informacyjnych

### Idea

Należy oszacować modele ARMA  $(p, q)$  dla wszystkich możliwych kombinacji parametrów  $p = 1, 2, \dots, P$  oraz  $q = 1, 2, \dots, Q$ , a następnie obliczyć dla nich wartości wybranego kryterium informacyjnego. Minimalna wartość kryterium wyznacza optymalną parę parametrów  $p$  i  $q$ .

# Proces ARMA

## Kryteria informacyjne

Niech  $L_{p,q}$  oznacza wiarygodność modelu ARMA  $(p, q)$ .

### Kryterium informacyjne Akaike (AIC)

$$\text{AIC}_{p,q} = -2 \ln L_{p,q} + 2(p + q + 1)$$

### Bayesowskie kryterium informacyjne (BIC)

$$\text{BIC}_{p,q} = -2 \ln L_{p,q} + (p + q + 1) \ln T$$

# Proces ARMA

## Podział metod estymacji

### Metody estymacji:

- Metody estymacji parametrów modelu AR ( $p$ ) :
  - równania Yule'a-Walkera,
  - metoda najmniejszych kwadratów,
  - metoda największej wiarygodności.
- Metody estymacji parametrów modelu ARMA ( $p, q$ ) :
  - metoda największej wiarygodności.



# Proces ARMA

## Idea metod estymacji

### Równania Yule'a-Walkera

Równania Yule'a-Walkera to liniowy układ równań pozwalający na wyrażenie parametrów autoregresji za pomocą współczynników autokorelacji. Oszacowania parametrów modelu  $AR(p)$  otrzymujemy zastępując we wspomnianym układzie współczynniki autokorelacji ich estymatorami, a następnie rozwiązując układ.

### Metoda najmniejszych kwadratów

Wykorzystanie klasycznej MNK do stacjonarnego szeregu czasowego typu  $AR(p)$ . Uzysane w ten sposób estymatory będą zgodne z estymatorami metody największej wiarygodności.

### Metoda największej wiarygodności

Metoda polegająca na maksymalizacji funkcji największej wiarygodności procesu  $ARMA(p, q)$ .

# Proces ARMA

## Prognoza

Interesuje nas prognoza na  $h$  okresów w przód:

$$X_{t+h} = \sum_{k=1}^p \rho_k X_{t+h-k} + \sum_{k=0}^q \theta_k \epsilon_{t-k},$$

gdzie  $\theta_0 = 1$ .

Możemy wyrazić ją jako warunkową wartość oczekiwaną:

$$\begin{aligned}\hat{X}_t(h) &= \mathbb{E}(X_{t+h} \mid X_t, X_{t-1}, \dots), \\ \mathbb{E}(X_{t+j} \mid X_t, X_{t-1}, \dots) &= \begin{cases} X_{t+j}, & j \leq 0, \\ \hat{X}_t(j), & j > 0, \end{cases} \\ \mathbb{E}(\epsilon_{t+j} \mid \epsilon_t, \epsilon_{t-1}, \dots) &= \begin{cases} \epsilon_{t+j}, & j \leq 0, \\ 0, & j > 0. \end{cases}\end{aligned}$$

# Proces ARIMA

## Proces ARIMA

Szereg czasowy  $X_t$  nazwiemy procesem ARIMA  $(p, d, q)$ , jeżeli szereg czasowy  $\Delta^d X_t$  jest procesem ARMA  $(p, q)$ .

Z powyższej definicji wynika, że proces ARIMA  $(p, d, q)$  jest opisywany przez następujące równanie:

$$\varphi(B) (\Delta^d X_t) = \theta(B) \epsilon_t.$$

# Multiplikatywny proces ARMA

## Intuicja

Niech proces  $X_t$  charakteryzuje równanie

$$\varphi_X(B) X_t = \theta_X(B) \epsilon_t,$$

natomiast proces  $\epsilon_t$  równanie

$$\varphi_\epsilon(B) \epsilon_t = \theta_\epsilon(B) \eta_t,$$

gdzie  $\eta_t \sim \text{WN}(0, \sigma^2)$ . Składając powyższe równania uzyskujemy

$$\varphi_\epsilon(B) \varphi_X(B) X_t = \theta_X(B) \theta_\epsilon(B) \eta_t.$$

**Uwaga.** Powyższe złożenie dwóch procesów ARMA pozostaje nadal procesem ARMA.

# Multiplikatywny proces ARMA

## Definicja

### Multiplikatywny proces ARMA

Szereg czasowy  $X_t$  nazwiemy multiplikatywnym procesem  $\text{ARMA}(p, q) \times (P, Q)_s$ , jeżeli spełnia on równanie

$$\Phi(B^s)X_t = \Theta(B^s)\epsilon_t,$$

gdzie

- $\Phi$  — operator analogiczny do  $\varphi$  rzędu  $P$ ,
- $\Theta$  — operator analogiczny do  $\theta$  rzędu  $Q$ ,
- $\epsilon_t$  — proces  $\text{ARMA}(p, q)$ .

# Multiplikatywny proces ARMA

## Właściwości

**Reprezentacja.** Proces  $\text{ARMA}(p, q) \times (P, Q)_s$  jest specyficznym przypadkiem procesu  $\text{ARMA}(p + sP, q + sQ)$ .

**Estymacja.** Estymacja parametrów multiplikatywnych procesów ARMA odbywa się przez osobną estymację parametrów każdego z procesów ARMA wchodzących w jego skład.

# Sezonowy proces ARIMA

## Sezonowy proces ARIMA

Szereg czasowy  $X_t$  nazwiemy sezonowym procesem ARIMA  $(p, d, q) \times (P, D, Q)_s$ , jeżeli spełnia on równanie

$$\Phi(B^s)\phi(B)\Delta_s^D\Delta^dX_t = \Theta(B^s)\theta(B)\epsilon_t,$$

gdzie

- $\epsilon_t$  — biały szum,
- $\Delta_s^D\Delta^dX_t$  — proces stacjonarny.

# Stylizowane fakty

## Stylizowane fakty dla stóp zwrotu:

- Rozkłady stóp zwrotu mają grubsze ogony niż rozkład normalny.
- Wartości stóp zwrotu są nieskorelowane, ale ich kwadraty są skorelowane.
- Duże zmiany wartości stóp zwrotu następują często po wcześniejszych dużych zmianach.



# Model ARCH

## Model ARCH

Powiemy, że szereg czasowy  $r_t$  jest procesem ARCH( $p$ ), jeżeli

$$\begin{aligned}r_t &= \sigma_t \epsilon_t, \\ \sigma_t^2 &= \alpha_0 + \sum_{j=1}^p \alpha_j r_{t-j}^2,\end{aligned}$$

gdzie

- $\epsilon_t$  iid WN(0, 1),
- $\alpha_0 > 0$ ,
- $\alpha_j \geq 0$  dla  $j = 1, 2, \dots, p$ .

**Uwaga.** Model ARCH jest często wykorzystywany do opisu reszt w modelach ARMA.

# Stacjonarność

## Stacjonarność

Stacjonarne szeregi czasowe typu ARCH ( $p$ ) spełniają nierówność

$$\sum_{j=1}^p \alpha_j < 1.$$

# Warunkowa wariancja

Niech  $\mathcal{R}_\tau$  będzie zbiorem wszystkich informacji o szeregu czasowym  $r_t$  do chwili czasu  $\tau$ . Wówczas:

$$\text{Var}(r_t | \mathcal{R}_{t-1}) = \mathbb{E}(r_t^2 | \mathcal{R}_{t-1}) - \mathbb{E}^2(r_t | \mathcal{R}_{t-1}),$$

$$\text{Var}(r_t | \mathcal{R}_{t-1}) = \mathbb{E}(\sigma_t^2 \epsilon_t^2 | \mathcal{R}_{t-1}) - \mathbb{E}^2(\sigma_t \epsilon_t | \mathcal{R}_{t-1}),$$

$$\text{Var}(r_t | \mathcal{R}_{t-1}) = \sigma_t^2 \mathbb{E}(\epsilon_t^2 | \mathcal{R}_{t-1}) - \sigma_t^2 \mathbb{E}^2(\epsilon_t | \mathcal{R}_{t-1}),$$

$$\text{Var}(r_t | \mathcal{R}_{t-1}) = \sigma_t^2 \mathbb{E}(\epsilon_t^2) - \sigma_t^2 \mathbb{E}^2(\epsilon_t),$$

$$\text{Var}(r_t | \mathcal{R}_{t-1}) = \sigma_t^2.$$

**Wniosek.**  $\sigma_t^2$  jest warunkową wariancją procesu  $r_t$  pod warunkiem przeszłości  $\mathcal{R}_{t-1}$ .

# Efekt ARCH

Test Engle'a

Szacujemy parametry modelu:

$$r_t^2 = \alpha_0 + \sum_{j=1}^p \alpha_j r_{t-j}^2 + \eta_t, \eta_t \text{ iid WN}(0, s).$$

Testujemy hipotezę postaci:

$$H_0 : \sum_{j=1}^p \alpha_j^2 = 0.$$

Statystyka testowa przyjmuje postać:

$$LM = TR^2 \rightarrow \chi_p^2,$$

gdzie  $R^2$  to współczynnik determinacji modelu wyjściowego.

# Efekt ARCH

## Test McLeod-Li

Badamy szereg czasowy kwadratów wartości szeregu czasowego wyjściowego  $r_t$ .

Testujemy hipotezę postaci

$$H_0 : \sum_{j=1}^h \rho_j^2 = 0.$$

Statystyka testowa przyjmuje postać:

$$T_{LB} = n(n+2) \sum_{j=1}^h \frac{\hat{\rho}_j^2}{n-j} \rightarrow \chi_h^2,$$

gdzie

$$\hat{\rho}_j = \frac{\sum_{t=h+1}^T r_t^2 r_{t-h}^2}{\sum_{t=1}^T r_t^4}.$$

# Model GARCH

## Model GARCH

Powiemy, że szereg czasowy  $r_t$  jest procesem GARCH  $(p, q)$ , jeżeli

$$\begin{aligned}r_t &= \sigma_t \epsilon_t, \\ \sigma_t^2 &= \alpha_0 + \sum_{j=1}^q \alpha_j r_{t-j}^2 + \sum_{j=1}^p \beta_j \sigma_{t-j}^2,\end{aligned}$$

gdzie

- $\epsilon_t$  iid WN  $(0, 1)$ ,
- $\alpha_0 > 0$ ,
- $\alpha_j \geq 0$  dla  $j = 1, 2, \dots, q$ ,
- $\beta_j \geq 0$  dla  $j = 1, 2, \dots, p$ .

**Uwaga.** Model GARCH jest często wykorzystywany do opisu reszt w modelach ARMA.

# Właściwości

- Przy spełnieniu odpowiednich założeń model GARCH można sprowadzić do postaci modelu ARCH.
- Model GARCH  $(p, q)$  można przedstawić w postaci modelu ARMA  $(m, p)$  dla szeregu  $r_t^2$ , gdzie  $m = \max(p, q)$ .

## Stacjonarność

Stacjonarne szeregi czasowe typu GARCH  $(p, q)$  spełniają nierówność

$$\sum_{j=1}^q \alpha_j + \sum_{j=1}^p \beta_j < 1.$$

# Estymacja

Estymacja modeli klasy GARCH odbywa się z wykorzystaniem metody największej wiarygodności. Maksymalizuje się funkcję log-wiarygodności

$$L_T(\boldsymbol{\theta}) = \sum_{t=1}^T \ell_t(\boldsymbol{\theta}),$$

gdzie

- $\boldsymbol{\theta}$  — wektor wszystkich parametrów modelu,
- $\ell_t(\boldsymbol{\theta})$  — funkcja log-wiarygodności dla obserwacji z chwili czasu  $t$ .



# Estymacja

Przypadek reszt o rozkładzie normalnym

Niech dane będzie równanie

$$r_t = \sigma_t \epsilon_t,$$

gdzie  $\epsilon_t$  iid  $\mathcal{N}(0, 1)$ .

Funkcja log-wiarogodności dla tego równania w chwili czasu  $t$  wyraża się wzorem

$$\ell_t(\theta) = \log \frac{1}{\sqrt{2\pi}\sigma_t} e^{-\frac{r_t^2}{2\sigma_t^2}} = -\frac{r_t^2}{2\sigma_t^2} - \log \sigma_t - \log \sqrt{2\pi}.$$

Finalna postać tej funkcji zależy od sposobu zdefiniowania warunkowej wariancji  $\sigma_t^2$  w danym modelu klasy GARCH.

# Ocena jakości modelu

## Idea

### Idea

Inwestor jest bardziej zainteresowany poznaniem kierunku zmian kursu instrumentu finansowego, niż dokładną wartością tego kursu.

# Ocena jakości modelu

## Miary zgodności kierunku zmian stopy zwrotu

Niech:

- $r_t$  — rzeczywista wartość stopy zwrotu w chwili czasu  $t$ ,
- $\hat{r}_t$  — predykowana wartość stopy zwrotu w chwili czasu  $t$ .

Podstawowe miary zgodności kierunku zmian stopy zwrotu to:

$$Q_1 = \frac{\#\{t : r_t \hat{r}_t > 0\}}{\#\{t : r_t \hat{r}_t \neq 0\}},$$
$$Q_2 = \frac{\#\{t : r_{t-1} r_t < 0 \wedge r_t \hat{r}_t > 0\}}{\#\{t : r_{t-1} r_t < 0 \wedge r_t \hat{r}_t \neq 0\}}.$$

# Ocena jakości modelu

## Modyfikacje miary $Q_1$

Uwzględniając koszt transakcji w wysokości  $g$  możemy miarę  $Q_1$  zmodyfikować w następujący sposób:

$$Q'_1 = \frac{\#\{t : r_t > g \wedge r_t \hat{r}_t > 0\}}{\#\{t : r_t > g \wedge r_t \hat{r}_t \neq 0\}}.$$

W przypadku modeli pozwalających szacować wyłącznie zmienność stopy zwrotu  $\sigma_t$  (np. modele GARCH bez części ARIMA) możemy zastosować następującą modyfikację miary  $Q_1$  :

$$Q_1^x = \frac{\#\{t : r_t \Delta \hat{\sigma}_t < 0\}}{\#\{t : r_t \Delta \hat{\sigma}_t \neq 0\}}.$$

# Model GARCH-M

# Model EGARCH

# Model TGARCH

# Kointegracja

**Idea.** Chcemy wiedzieć, czy bazując na pewnej grupie niestacjonarnych szeregów czasowych możemy bezpiecznie zbudować model.

## Kointegracja

Powiemy, że szeregi czasowe  $X_{1,t}, X_{2,t}, \dots, X_{n,t}$  są skointegrowane w stopniu  $(d, b)$ , jeżeli dla każdego  $i = 1, 2, \dots, n$  zachodzi

$$X_{i,t} \sim I(d)$$

oraz istnieją takie wartości  $\beta_1, \beta_2, \dots, \beta_n$ , że

$$\beta_1 X_{1,t} + \beta_2 X_{2,t} + \dots + \beta_n X_{n,t} \sim I(d - b).$$

**Intuicja.** Relacje pomiędzy skointegrowanymi niestacjonarnymi szeregami czasowymi pozostają w długiej perspektywie czasowej niezmiennie.



# Testowanie kointegracji

## Procedura Engle'a-Grangera.

- 1 Należy zweryfikować czy wszystkie analizowane szeregi czasowe charakteryzuje ten sam stopień integracji.
- 2 Należy zbudować model regresji liniowej wielorakiej w którym jeden z analizowanych szeregów pełni rolę zmiennej objaśnianej, pozostałe natomiast zmiennych objaśniających.
- 3 Należy przetestować stopień integracji reszt wyznaczonego w poprzednim kroku modelu.

# Model ECM

## Model korekty błędem (ECM)

$$\Delta y_t = \mu + \alpha (y_{t-1} - \beta_0 - \beta_1 x_{t-1}) + \sum_{i=1}^{k-1} \theta_i \Delta y_{t-i} + \sum_{i=0}^{k-1} \gamma_i \Delta x_{t-i} + \epsilon_t$$

### Interpretacja:

- $y_{t-1} = \beta_0 + \beta_1 x_{t-1}$  — równanie równowagi długookresowej,
- $y_{t-1} - \beta_0 - \beta_1 x_{t-1}$  — odchylenie od równowagi długookr.,
- $\alpha$  — współczynnik opisujący szybkość dostosowywania się zmiennej objaśnianej do poziomu równowagi długookresowej (w stabilnym modelu  $\alpha < 0$ ).
- $\theta_i, \gamma_i$  — współczynniki opisujące dynamikę krótkookresową.

# Stosowalność

**Uwaga.** Twierdzenie Grangera o reprezentacji gwarantuje nam możliwość zastosowania mechanizmu korekty błędem względem skointegrowanych szeregów czasowych.

# Estymacja

- 1 Estymacja parametrów równania równowagi długookresowej

$$y_{t-1} = \beta_0 + \beta_1 x_{t-1}.$$

- 2 Skonstruowanie szeregów czasowych

$$\epsilon_t = y_t - \beta_0 - \beta_1 x_t,$$

$$\Delta x_t = x_t - x_{t-1},$$

$$\Delta y_t = y_t - y_{t-1}.$$

- 3 Estymacja parametrów równania modelu korekty błędem

$$\Delta y_t = \mu + \alpha \epsilon_{t-1} + \sum_{i=1}^{k-1} \theta_i \Delta y_{t-i} + \sum_{i=0}^{k-1} \gamma_i \Delta x_{t-i} + \epsilon_t$$

# Pytania?

# Dziękuję za uwagę!