

# Ekonometria Finansowa

## Wielowymiarowe modele szeregów czasowych

mgr Paweł Jamer<sup>1</sup>

Doktorant, Katedra Ekonometrii i Statystyki SGGW  
Ekspert ds. Modelowania Danych, Polskie Technologie  
Konsultant Zewnętrzny, Polkomtel

7 października 2016

---

<sup>1</sup>pawel.jamer@gmail.com

## Model Wektorowej Autoregresji (VAR)

Niech dany będzie szereg czasowy  $\mathbf{Y}_t = [Y_{1,t}, Y_{2,t}, \dots, Y_{n,t}]'$ . Modelem wektorowej autoregresji o  $p$  opóźnień szeregu  $\mathbf{Y}_t$  nazwiemy model opisany równaniem

$$\mathbf{Y}_t = \sum_{i=1}^p \mathbf{A}_i \mathbf{Y}_{t-i} + \boldsymbol{\epsilon}_t,$$

gdzie

- $\mathbb{E}(\boldsymbol{\epsilon}_t) = \mathbf{0}$ ,
- $\mathbb{E}(\boldsymbol{\epsilon}_t \boldsymbol{\epsilon}_t') = \boldsymbol{\Omega}$  — macierz dodatnio określona,
- $\mathbb{E}(\boldsymbol{\epsilon}_t \boldsymbol{\epsilon}_s') = \mathbf{0}$  dla  $t \neq s$ .

**Uwaga.** Model wektorowej autoregresji o  $p$  opóźnień przyjęło się oznaczać symbolem  $\text{VAR}(p)$ .

## Model VAR :

- ma często dobre właściwościami progностyczne i symulacyjne,
- dopuszcza pełną dowolność co do wartości parametrów,
- uwzględnia występowanie zależności pomiędzy zmiennymi,
- traktuje wszystkie zmienne jako objaśniane oraz objaśniające,
- nie jest związany z żadną konkretną teorią ekonomiczną,
- wymaga oszacowania wielu parametrów.

# Reprezentacja VAR(1)

Rozpatrzmy proces VAR(p)

$$\mathbf{Y}_t = \sum_{i=1}^p \mathbf{A}_i \mathbf{Y}_{t-i} + \epsilon_t.$$

Proces ten zapisać możemy jako

$$\begin{bmatrix} \mathbf{Y}_t \\ \mathbf{Y}_{t-1} \\ \vdots \\ \mathbf{Y}_{t-(p-1)} \end{bmatrix} = \begin{bmatrix} \mathbf{A}_1 & \cdots & \mathbf{A}_{p-1} & \mathbf{A}_p \\ \mathbf{I} & \cdots & \mathbf{0} & \mathbf{0} \\ \vdots & \ddots & \vdots & \vdots \\ \mathbf{0} & \cdots & \mathbf{I} & \mathbf{0} \end{bmatrix} \begin{bmatrix} \mathbf{Y}_{t-1} \\ \mathbf{Y}_{t-2} \\ \vdots \\ \mathbf{Y}_{t-p} \end{bmatrix} + \begin{bmatrix} \epsilon_t \\ \mathbf{0} \\ \vdots \\ \mathbf{0} \end{bmatrix},$$

a zatem jako proces VAR(1).

## Model Wektorowej Średniej Ruchomej (VMA)

Niech dany będzie szereg czasowy  $\mathbf{Y}_t = [Y_{1,t}, Y_{2,t}, \dots, Y_{n,t}]'$ . Modelem wektorowej średniej ruchomej o  $q$  opóźnień szeregu  $\mathbf{Y}_t$  nazwiemy model opisany równaniem

$$\mathbf{Y}_t = \boldsymbol{\epsilon}_t + \sum_{i=1}^q \mathbf{M}_i \boldsymbol{\epsilon}_{t-i},$$

gdzie

- $\mathbb{E}(\boldsymbol{\epsilon}_t) = \mathbf{0}$ ,
- $\mathbb{E}(\boldsymbol{\epsilon}_t \boldsymbol{\epsilon}_t') = \boldsymbol{\Omega}$  — macierz dodatnio określona,
- $\mathbb{E}(\boldsymbol{\epsilon}_t \boldsymbol{\epsilon}_s') = \mathbf{0}$  dla  $t \neq s$ .

**Uwaga.** Model wektorowej średniej ruchomej o  $q$  opóźnień przyjęło się oznaczać symbolem  $\text{VMA}(q)$ .

# Reprezentacja $VMA(\infty)$

Dowolny model wektorowej autoregresji przedstawić można w postaci modelu wektorowej średniej ruchomej o nieskończonej liczbie opóźnień

$$Y_t = \epsilon_t + \sum_{i=1}^{\infty} M_i \epsilon_{t-i}.$$

W szczególności model VAR(1) przyjmuje postać

$$Y_t = \epsilon_t + \sum_{i=1}^{\infty} A^i \epsilon_{t-i},$$

# Stabilność

## Definicja

### Stabilność

Model VAR nazywamy stabilnym, jeżeli

$$\lim_{k \rightarrow \infty} (\mathbf{A}^k) = \mathbf{0},$$

gdzie  $\mathbf{A}$  jest macierzą parametrów reprezentacji VAR (1) analizowanego modelu VAR.

**Intuicja.** Wpływ zaburzenia  $\epsilon_t$  na  $\mathbf{Y}_t$  wygasa w miarę czasu.

### Twierdzenie

Model VAR( $p$ ) jest stabilny, gdy

$$\det \left( I - \sum_{i=1}^p \mathbf{A}_i z^i \right) \neq 0$$

dla  $|z| \leq 0$ .



### **Rekursywna estymacja parametrów.**

Szacuje się parametry modelu VAR na podstawie pierwszych  $\tau$  obserwacji, gdzie  $\tau$  przyjmuje kolejno wartości  $T_0, T_0 + 1, \dots, T$ . Jako  $T_0$  wybiera się najmniejszą wartość dla której możliwe jest zbudowanie modelu. Następnie rysuje się wykresy szeregów uzyskanych oszacowań wraz ze średnimi błędami szacunku.

### **Testy statystyczne.**

- Test CUSUM.
- Test Chowa.

# Rozszerzenia modelu VAR

## Zmienne deterministyczne

W równaniu modelu VAR często uwzględnia się zmienne deterministyczne (np. stałą, trend, sezonowość):

$$\mathbf{Y}_t = \mathbf{A}_0 \mathbf{D}_t + \sum_{i=1}^p \mathbf{A}_i \mathbf{Y}_{t-i} + \epsilon_t,$$

gdzie

- $\mathbf{D}_t$  — macierz zmiennych deterministycznych,
- $\mathbf{A}_0$  — macierz parametrów związanych z  $\mathbf{D}_t$ .

# Rozszerzenia modelu VAR

## Zmienne egzogeniczne

Innym typem często uwzględnianych w modelu VAR zmiennych są zmienne stochastyczne nie podlegające modelowaniu (zmienne egzogeniczne):

$$\mathbf{Y}_t = \sum_{i=1}^p \mathbf{A}_i \mathbf{Y}_{t-i} + \mathbf{B} \mathbf{Z}_t + \epsilon_t,$$

gdzie

- $\mathbf{Z}_t$  — macierz zmiennych egzogenicznych,
- $\mathbf{B}$  — macierz parametrów związanych z  $\mathbf{Z}_t$ .

# Egzogeniczność

## Definicje

### Słaba egzogeniczność

Zmienna  $z_t$  jest nazywana słabo egzogeniczną dla wektora parametrów  $\theta$  jeżeli estymacja parametrów  $\theta$  z modelu warunkowego warunkowanego zmienną  $z_t$  nie powoduje utraty informacji względem estymacji tych parametrów z modelu pełnego.

### Silna egzogeniczność

Zmienna  $z_t$  jest nazywana silnie egzogeniczną dla wektora parametrów  $\theta$ , jeżeli jest ona dla niego słabo egzogeniczna oraz prognoza  $Y_t$  może zostać przeprowadzona bez utraty dokładności na podstawie modelu warunkowego pod warunkiem  $z_t$ .

# Selekcja optymalnego $p$

Metody selekcji optymalnej wartości parametru  $p$  :

- przesłanki teoretyczne,
- kryteria informacyjne,
- testy istotności parametrów dla ostatnich opóźnień,
- analiza reszt modelu (np. statystyka Ljunga-Boxa).

# Selekcja optymalnego $p$

## Kryteria informacyjne

Wyboru optymalnej wartości parametru  $p$  dokonuje się minimalizując wartość wybranego kryterium informacyjnego.

### Kryterium Akaike

$$AIC = -2 \frac{\ln(L)}{T} + k \frac{2}{T}$$

### Kryterium Schwarza

$$SC = -2 \frac{\ln(L)}{T} + k \frac{\ln(T)}{T}$$

### Kryterium Hannana-Quinna

$$HQ = -2 \frac{\ln(L)}{T} + k \frac{\ln(\ln(T))}{T}$$

Jeżeli każde z równań modelu VAR posiada ten sam zbiór zmiennych objaśniających, to estymacja parametrów całego modelu może zostać przeprowadzona poprzez zastosowanie metody najmniejszych kwadratów do każdego z równań osobno.

Alternatywą jest zastosowanie metody największej wiarygodności do wszystkich równań modelu łącznie.

## Kopula

Funkcja  $C : \mathbb{I}^2 \rightarrow \mathbb{I}$  spełniająca następujące warunki

- ❶  $C(0, t) = C(t, 0) = 0,$
- ❷  $C(1, t) = C(t, 1) = t,$
- ❸  $C(u_2, v_2) - C(u_1, v_2) - C(u_2, v_1) + C(u_1, v_1) \geq 0,$

dla  $t, u_1, u_2, v_1, v_2 \in \mathbb{I}, u_1 \leq u_2, v_1 \leq v_2,$

**Intuicja.** Kopula to dystrybuanta wielowymiarowa, której dystrybuanty brzegowe pochodzą z rozkładu jednostajnego na  $\mathbb{I}$ .



# Twierdzenie Sklara

## Twierdzenie

**Niech:**

- $F$  — dystrybuanta łączna 2-wymiarowa,
- $F_1, F_2$  — dystrybuanty brzegowe  $F$ .

**Wówczas:**

- istnieje kopula  $C$  taka, że dla dowolnego punktu  $(x_1, x_2) \in \overline{\mathbb{R}}^2$  zachodzi

$$F(x_1, x_2) = C(F_1(x_1), F_2(x_2)). \quad (1)$$

**Ponadto:**

- jeśli  $F_1, F_2$  są ciągłe, to  $C$  jest wyznaczona jednoznacznie.
- jeśli funkcja  $C$  jest kopulą, a  $F_1, F_2$  są dystrybuantami, to zależność (1) wyznacza dystrybuantę wielowymiarową  $F$ .

# Twierdzenie Sklara

## Wnioski

**Interpretacja.** Problem modelowania wielowymiarowego szeregu czasowego rozdzielić można na dwa podproblemy

- modelowania jednowymiarowych szeregów składowych,
- modelowania współzależności łączących te szeregi.

**Uwaga.** Twierdzenie Sklara przenosi się bez zmian również na przypadek rozkładów warunkowych.

**Uwaga.** Łączenie jednowymiarowych szeregów czasowych za pomocą różnych kopul pozwala skupić się na modelowaniu różnych współzależności.

# Miary współzależności

## Współczynnik Kendalla

### Współczynnik $\tau$ Kendalla

Niech  $X_{i,1}, X_{i,2} \sim X_i$  dla  $i = 1, 2$ . Wówczas współczynnikiem  $\tau$  Kendalla zmiennych  $X_1$  i  $X_2$  nazwiemy

$$\tau(X_1, X_2) = P((X_{1,1} - X_{1,2})(X_{2,1} - X_{2,2}) > 0) - P((X_{1,1} - X_{1,2})(X_{2,1} - X_{2,2}) < 0).$$

### Twierdzenie

Niech  $X_1$  i  $X_2$  będą ciągłymi zmiennymi losowymi o współzależnościach opisanych kopulą  $C$ . Wówczas  $\tau$  Kendalla zmiennych losowych  $X_1$  i  $X_2$  daje się przedstawić jako

$$\tau(X_1, X_2) = 4 \int_0^1 \int_0^1 C(u, v) dC(u, v) - 1.$$

# Miary współzależności

## Współczynnik Spearmana

### Współczynnik $\rho$ Spearmana

Niech  $X_1$  i  $X_2$  będą ciągłymi zmiennymi losowymi o dystrybuantach odpowiednio  $F_1$  i  $F_2$ . Niech  $\rho$  oznacza współczynnik korelacji Pearsona. Wówczas współczynnikiem  $\rho$  Spearmana nazwiemy

$$\rho_S(X_1, X_2) = \rho(F_1(X_1), F_2(X_2)).$$

### Twierdzenie

Niech  $X_1$  i  $X_2$  będą ciągłymi zmiennymi losowymi o współzależnościach opisanych kopułą  $C$ . Wówczas  $\rho$  Spearmana zmiennych losowych  $X_1$  i  $X_2$  daje się przedstawić jako

$$\rho_S(X_1, X_2) = 12 \int_0^1 \int_0^1 C(u, v) \, du \, dv - 3$$

# Miary współzależności

## Współczynniki zależności asymptotycznych

### Współczynnik zależności w dolnym ogonie

Niech  $X_1$  i  $X_2$  będą ciągłymi zmiennymi losowymi o dystrybuantach odpowiednio  $F_1$  i  $F_2$ . Wówczas współczynnikiem zależności w dolnym ogonie nazwiemy granicę

$$\lambda_L = \lim_{\alpha \rightarrow 0+} P\left(X_2 \leq F_2^{-1}(\alpha) \mid X_1 \leq F_1^{-1}(\alpha)\right)$$

o ile granica ta istnieje.

# Miary współzależności

## Współczynniki zależności asymptotycznych

### Współczynnik zależności w górnym ogonie

Niech  $X_1$  i  $X_2$  będą ciągłymi zmiennymi losowymi o dystrybuantach odpowiednio  $F_1$  i  $F_2$ . Wówczas współczynnikiem zależności w górnym ogonie nazwiemy granicę

$$\lambda_U = \lim_{\alpha \rightarrow 1-} P\left(X_2 > F_2^{-1}(\alpha) \mid X_1 > F_1^{-1}(\alpha)\right)$$

o ile granica ta istnieje.

# Miary współzależności

## Współczynniki zależności asymptotycznych

### Twierdzenie

Niech  $X_1$  i  $X_2$  będą ciągłymi zmiennymi losowymi o współzależnościach opisanych kopulą  $C$ . Wówczas współczynniki zależności asymptotycznych zmiennych losowych  $X_1$  i  $X_2$  dają się przedstawić jako

$$\begin{aligned}\lambda_L(X_1, X_2) &= \lim_{\alpha \rightarrow 0+} \frac{C(\alpha, \alpha)}{\alpha}, \\ \lambda_U(X_1, X_2) &= 2 - \lim_{\alpha \rightarrow 1-} \frac{1 - C(\alpha, \alpha)}{1 - \alpha}.\end{aligned}$$

Zastosowanie twierdzenia Sklara pozwala przedstawić funkcję log-wiarogodności wielowymiarowego szeregu czasowego jako:

$$\ell(\boldsymbol{\theta}, \boldsymbol{\alpha}_1, \boldsymbol{\alpha}_2) = \sum_{i=1}^2 \ell_i(\boldsymbol{\alpha}_i) + \ell_C(\boldsymbol{\theta}, \boldsymbol{\alpha}_1, \boldsymbol{\alpha}_2),$$

gdzie

- $\ell_i$  — funkcja log-wiarogodności  $i$ -tego jednowymiarowego szeregu czasowego brzegowego,
- $\ell_C$  — funkcja log-wiarogodności kopuli,
- $\boldsymbol{\alpha}_i$  — wektor parametrów  $i$ -tego jednowymiarowego szeregu czasowego brzegowego,
- $\boldsymbol{\theta}$  — wektor parametrów kopuli.



Przedstawiona postać funkcji  $\ell(\boldsymbol{\theta}, \alpha_1, \alpha_2)$  sugeruje możliwość rozdzielenia procesu estymacji parametrów modelu metodą największej wiarygodności na dwa etapy:

- 1 estymację parametrów jednowymiarowych szeregów czasowych  $\alpha_1$  i  $\alpha_2$  na podstawie odpowiednio  $\ell_1(\alpha_1)$  i  $\ell_2(\alpha_2)$ ,
- 2 estymację parametrów kopuli  $\boldsymbol{\theta}$  na podstawie  $\ell_C(\boldsymbol{\theta}, \hat{\alpha}_1, \hat{\alpha}_2)$ , gdzie  $\hat{\alpha}_1$  i  $\hat{\alpha}_2$  to estymatory parametrów odpowiednio  $\alpha_1$  i  $\alpha_2$  uzyskane w pierwszym kroku estymacji.

Powyższa metoda estymacji nosi nazwę **metody IFM**.

**Uwaga** Zostało udowodnione, że metoda IFM posiada satysfakcjonujące właściwości statystyczne.

**Uwaga.** Metoda IFM pozwala stanowczo uprościć proces estymacji parametrów złożonego modelu wielowymiarowego poprzez rozłożenie go na dwa o wiele prostsze podproblemy, estymacji parametrów jednowymiarowych modeli brzegowych oraz estymacji parametrów opisujących współzależności tych modeli.

# Przykład

## Kopule eliptyczne

### Kopuła normalna

Kopułą normalną o korelacji liniowej  $\rho$  nazwiemy funkcję

$$C_{\rho}^g(u_1, u_2) = \frac{1}{2\pi\sqrt{1-\rho^2}} \int_{-\infty}^{z_{u_1}} \int_{-\infty}^{z_{u_2}} e^{\frac{2\rho s_1 s_2 - s_1^2 - s_2^2}{2(1-\rho^2)}} ds_1 ds_2,$$

gdzie

- $z_{u_i}$  — kwantyl  $u_i$  standardowego rozkładu normalnego.

### Kopuła t-Studenta

Kopułą t-Studenta o  $\nu$  stopniach swobody i korelacji liniowej  $\rho$  nazwiemy funkcję

$$C_{\nu, \rho}^t(u_1, u_2) = \frac{1}{2\pi\sqrt{1-\rho^2}} \int_{-\infty}^{t_{\nu}^{-1}(u_1)} \int_{-\infty}^{t_{\nu}^{-1}(u_2)} \left(1 + \frac{s_1^2 + s_2^2 - 2\rho s_1 s_2}{\nu(1-\rho^2)}\right)^{-\frac{\nu+2}{2}} ds_1 ds_2,$$

gdzie

- $t_{\nu}^{-1}(u_i)$  — kwantyl  $u_i$  rozkładu t-Studenta o  $\nu$  st. swobody.
- $\Gamma(\alpha) = \int_0^{\infty} x^{\alpha-1} e^{-x} dx$ , dla  $\alpha > 0$ .

### Model Copula-GARCH

Niech  $r_{1,t}, r_{2,t} \sim \text{GARCH}$ . Niech współzależności  $r_{1,t}$  i  $r_{2,t}$  opisuje kopuła  $C$ . Modelem Copula-GARCH szeregów czasowych  $r_{1,t}$  i  $r_{2,t}$  nazwiemy model opisany dystrybuantą wielowymiarową postaci

$$F(r_{1,t}, r_{2,t} | \mathcal{R}_{t-1}) = C(F_1(r_{1,t} | \mathcal{R}_{t-1}), F_2(r_{2,t} | \mathcal{R}_{t-1}) | \mathcal{R}_{t-1}),$$

gdzie

- $F_i$  — dystrybuanta  $r_{i,t}$  dla  $i = 1, 2$ ,
- $F$  — dystrybuanta łączna  $r_{1,t}$  i  $r_{2,t}$ .

# Pytania?

**Dziękuję za uwagę!**